

#### 1.4. Problema UNLP (optimizare neliniara fara constrangeri). Metoda gradientului.

O problema de optimizare neliniara unidimensionala fara constrangeri ((UNLP) rezida in determinarea vectorului coloana  $(x^*)^T = (x_1^*, \dots, x_n^*)^T$  pentru functia obiectiv  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  cu proprietatea ca

$$\min_{x \in \mathbb{R}^n} f(x) = f(x^*) = f(x_1^*, \dots, x_n^*)$$

Metodele numerice de cautare a minimumului reprezinta o procedura iterativa, astfel incat, pornind de la un vector initial  $x^{(0)}$ , se genereaza un sir de vectori  $(x^{(k)})_{k \geq 1}$ , pentru care

$$f(x^{(0)}) > f(x^{(1)}) > \dots > f(x^{(k)}) > \dots$$

Din punct de vedere formal deplasarea intre punctele  $x^{(k)}$  si  $x^{(k+1)}$  este data de relatia

$$x^{(k+1)} = x^{(k)} + \alpha_k d^{(k)},$$

unde vectorul  $d^{(k)}$  reprezinta directia de deplasare iar  $\alpha_k$  determina marimea acestei deplasari.

Conform sensului geometric al gradientului  $\nabla f(x)$  pentru functia  $f(x)$ , vectorul  $\nabla f(x)$  indica **directia cresterii celei mai rapide**. Prin urmare este firesc sa alegem in calitate de directie de deplasare directia **descresterii celei mai rapide (abrupte)**, adica directia opusa gradientului, **directie determinata de vectorul  $-\nabla f(x)$**  numita si **antigradient**.

Or, alegand antigradientul ca directie de deplasare, obtinem procedura iterativa in forma

$$x^{(k+1)} = x^{(k)} - \alpha_k \nabla f(x^{(k)}).$$

Valoarea parametrului  $\alpha_k$  este determinata din conditia minimizarii functiei  $f(x^{(k)} - \alpha \nabla f(x^{(k)}))$  in dependenta de  $\alpha$  in sensul ca

$$\alpha_k : f(x^{(k)} - \alpha_k \nabla f(x^{(k)})) = \min_{\alpha \in \mathbb{R}} f(x^{(k)} - \alpha \nabla f(x^{(k)})). \quad (1)$$

Aceasta metoda a gradientului in care lungimea pasului se alege din conditia (1) se numeste metoda celei mai rapide descresteri. Putem spune ca aceasta este **procedura ideala** pentru alegerea lungimii pasului, Insa din punct de vedere al aplicarii acestei metode pe calculator verificarea conditiei (1) devine dificila. In acest scop aceasta metoda esste modificata in felul urmator.

**Pasul 1.** Se alege o valoare arbitrara  $\alpha$  (una si aceeaasi pentru fiecare iteratie), se determina punctul  $z = x^{(k)} - \alpha \nabla f(x^{(k)})$  si se calculeaza  $f(z)$ ;

**Pasul 2.** Se verifica conditia

$$f(z) - f(x^{(k)}) \leq \delta \alpha \left\| \nabla f(x^{(k)}) \right\|^2, \quad (2)$$

unde  $\delta$  este o constanta arbitrara (de ex.  $\delta = 1/2$ ) din intervalul  $(0, 1)$ ;

**Pasul 3.** Daca este indeplinita inegalitatea (2), atunci valoarea  $\alpha$  este acceptata, luand  $\alpha_k = \alpha$ . In caz contrar se fractioneaza  $\alpha$  prin inmultirea lui cu un numar arbitrar  $\gamma$  (de ex.  $\gamma = 1/2$ ) din intervalul  $(0, 1)$ , procesul acesta continuand pana cand este satisfacuta conditia (2).

*Se recomanda ca procedura de calcul sa continue pana cand*

$$\left\| \nabla f(x^{(k)}) \right\| < \varepsilon,$$

unde  $\varepsilon > 0$  este considerata precizia atingerii minimumului.

Metoda gradientului in care  $\alpha_k$  este determinat conform algoritmului descris mai sus se numeste **metoda gradientului cu fractionarea pasului**.

Un exemplu de aplicare a acestui Algoritm poate fi gasit in lucrarea lui V. Moraru si E. Tutunaru, *Programare Matematica, UTM, Chisinau, 1999*.

### 1.5. Metoda directiilor conjugate.

Metoda directiilor conjugate poate fi privita ca pe o metoda intermediara intre metoda gradient, ce foloseste informatii de ordinul I si metodele ce folosesc informatii de ordinul II (metode de tip Newton). Aceasta metoda este motivata de dorinta de a accelera viteza de convergenta in metoda gradientului si, totodata, de a evita necesitatea de a folosi Hessiana. un caz particular al metodei directiilor conjugate este metoda gradientilor conjugati, care a fost initial dezvoltata pentru probleme patratic. Aceasta tehnica a fost extinsa asupra problemelor de optimizare generale, prin aproximare, deoarece se poate arata ca in apropierea unui punct de minim local functia obiectiv este, aproximativ, patratica.

#### 1.5.1. Metoda directiilor conjugate pentru QP.

Metoda directiilor conjugate este, deasemenea, o metoda de ordinul I, adica foloseste informatia extrasa din valoarea functiei si gradientului acesteia, insa prezinta o rata de convergenta mai buna decat a metodei gradient, cel putin, pentru cazul patratic. Sa luam urmatoarea problema patratica (QP) strict convexa:

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} (Ax, x) + b^T x + c,$$

unde  $A \succ 0$  (adica este o matrice pozitiv definita). Solutia optima a acestei probleme de optimizare este echivalenta cu rezolvarea unui sistem de ecuatii liniare de forma  $Ax = -b$ . Intrucat  $A$  este inversabila, solutia problemei de optimizare sau solutia sistemului liniar este  $x^* = -A^{-1}b$ . In cele mai multe cazuri, calculul inversei este foarte costisitor iar complexitatea aritmetica a unei metode de calcul numeric matriceal pentru gasirea solutiei este de ordinul  $O(n^3)$ . In cele ce urmeaza vom prezenta o metoda numerica de optimizare mai simpla si, de obicei, mai putin costisitoare numeric pentru aflarea solutiei optime  $x^*$ .

Este vorba de **algoritmul lui Hestenes-Stiefel pentru minimizarea unei functii patratic** (si rezolvarea unui sistem de ecuatii lineare cu matricea pozitiv definita):

**Pasul. 1.** Se alege arbitrar  $x^{(0)} \in \mathbb{R}^n$  si se determina  $\nabla f(x^{(0)})$ . Daca  $\nabla f(x^{(0)}) = 0$ , atunci  $x^{(0)}$  este o solutie optima. STOP. In caz contrar luam

$d^{(0)} = -\nabla f(x^{(0)})$ ,  $k = 0$  si trecem la pasul urmator.

**Pasul 2.** Se determina lungimea pasului  $\alpha_k$  de-a lungul directiei  $d^{(k)}$ , care pleaca din  $x^{(k)}$ , ceea ce revine la minimizarea in raport cu parametrul scalar  $\alpha$  al functiei  $\varphi(\alpha) = f(x^{(k)} + \alpha d^{(k)})$ . Determinarea lui  $\alpha_k$  poate fi realizata conform formulei

$$\alpha_k = -\frac{(\nabla f(x^{(k)}))^T d^{(k)}}{(A d^{(k)})^T d^{(k)}}$$

sau printr-o metoda de aproximare a punctelor de extrem pentru functii de o singura variabila.

**Pasul 3.** Se construiesc o aproximare noua:

$$x^{(k+1)} = x^{(k)} + \alpha_k d^{(k)}$$

si se calculeaza  $f(x^{(k+1)})$  si  $\nabla f(x^{(k+1)})$ . Daca  $\nabla f(x^{(k+1)}) = 0$ , atunci  $x^* = x^{(k+1)}$  este o solutie optima. STOP. In caz contrar trecem la pasul urmator.

**Pasul 4.** Se ia directia

$$d^{(k+1)} = -\nabla f(x^{(k+1)}) + \frac{\|\nabla f(x^{(k+1)})\|^2}{\|\nabla f(x^{(k)})\|^2} d^{(k)},$$

dupa care se trece la **Pasul 2**, luand  $k + 1$  inloc de  $k$ .

Pleand de la aproximatia initiala  $x^{(0)}$ , acest algoritm conduce la gasirea punctului de minim  $x^*$  al functiei patraticice dupa calculul a cel mult  $n$  directii conjugate.

**Exemplu.** Fie functia  $f(x_1, x_2) = x_1^2 + x_1 x_2 + \frac{1}{2} x_2^2 - 3x_1 - 2x_2$ . Observam ca aceasta poate fi scrisa in forma

$$f(x) = \frac{1}{2}(Ax, x) + b^T x,$$

unde

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}, b = (-3, -2)^T.$$

Luand aproximatia initiala  $x^{(0)} = (-3, -2)^T$ , vom obtine in 2 iteratii:

$$d^{(0)} = (1, 0)^T, \alpha_0 = \frac{1}{2}, x^{(1)} = \left(\frac{1}{2}, 2\right)^T;$$

$$d^{(1)} = \left(\frac{1}{4}, -\frac{1}{2}\right)^T, \alpha_0 = 2, x^{(2)} = (1, 1)^T = x^*.$$

### 1.5.2. Minimizarea unei functii strict convexe.

Asa cum am mentionat anterior, metoda lui Hestenes-Stiefel poate fi folosita si pentru minimizarea functiilor nepatraticice. In caz ca functia nu mai este una patratica este evident ca nu mai garantam convergenta intr-un numar finit de pasi. Algoritmul descris in p.1.5.1. se va relua, in caz nepatratic, in mod ciclic

dupa iteratia cu numarul  $n$ , inlocuind  $x^{(0)}$  cu  $x^{(n)}$ , atata timp cat  $\|d^{(k)}\| \geq \varepsilon$ , unde  $\varepsilon$  este eroarea de calcul admisa la aflarea punctului de minim. In felul acesta putem descrie metoda numita **metoda gradientului conjugat sau metoda lui Fletcher-Reeves**:

$$\begin{aligned} x^{(k+1)} &= x^{(k)} + \alpha_k d^{(k)}, \\ d^{(0)} &= -\nabla f(x^{(0)}), \\ d^{(k)} &= -\nabla f(x^{(k)}) + \beta_{k-1} d^{(k-1)}, k \geq 1, \\ \alpha_k &: f(x^{(k)} + \alpha_k d^{(k)}) = \min_{\alpha \geq 0} f(x^{(k)} + \alpha d^{(k)}). \end{aligned}$$

Metodele de directii conjugate se deosebesc prin modul in care se definesc coefficientii  $\beta_k$ ,  $k \geq 0$ . Astfel, in varianta sa originala, asa cum a fost ea propusa de Fletcher si Reeves acesti coefficienti se determina prin formula:

$$\beta_{k-1} = \begin{cases} \frac{\|\nabla f(x^{(k)})\|^2}{\|\nabla f(x^{(k-1)})\|^2}, k \notin I, \\ 0, k \in I, \end{cases}$$

unde  $I$  este o multime de indici de forma  $I = \{0, n, 2n, 3n, \dots\}$ , adica algoritmul se reînnoieste peste fiecare  $n$  pasi.

**O alta varianta a metodei gradientului conjugat** este cea propusa de **Polak si Ribiere** (1969), varianta in care

$$\beta_{k-1} = \begin{cases} \frac{(\nabla f(x^{(k)}), \nabla f(x^{(k)}) - \nabla f(x^{(k-1)}))}{\|\nabla f(x^{(k-1)})\|^2}, k \notin I, \\ 0, k \in I, \end{cases}$$

unde  $I = \{0, n, 2n, 3n, \dots\}$ .

**Remarca.** In cazul functiilor patratice aceste doua variante de calcul a coefficientilor  $\beta_k$  coincid. In cazul minimizarii functiilor convexe nepatratice, algoritmul propus de Fletcher si Reeves are proprietati de convergenta mai slabe, de aceea in acest caz este recomandat algoritmul lui Polak si Ribiere.